

Rapport de qualité — Données de scraping EventZilla

Projet : EventZilla — Analyse exploratoire des données (EDA)
Document : Rapport de qualité des fichiers de scraping
Source : EDA_Scrapping_Files_EventZilla.ipynb
Date : Février 2025

1. Introduction

Ce rapport décrit la **qualité**, la **méthodologie** et les **indicateurs (KPIs)** associés aux données de scraping utilisées dans le cadre du projet EventZilla. Les fichiers concernés alimentent des axes métier du cahier des charges (CDC) : suggestions de salles, potentiel de catégories d'événements, benchmark prix et analyse des jours fériés.

Les indicateurs proposés sont alignés sur le **CDC EventZilla** et sur le document **Analyse_CDC_Data_Scrapping_KPIs** (KPIs opérationnels, qualité, business, produit et **contextuels**). Les KPIs contextuels sont ceux alimentés ou enrichis par le scraping (jours fériés, benchmark prix, tendances, taille d'offre).

2. Synthèse : Fichiers scrappés et axes métier

Fichier	Axe métier	Usage CDC (sections 5.1 / 5.4 / 4.4)
venues_salles_tunisie_ranim.csv	Suggestions salles populaires	Alimenter les suggestions des salles les plus populaires en Tunisie (par région, type d'événement, contact).
tendances_evenementielles_tunisie.csv	Potentiel catégories à ajouter	Analyser les potentiels de catégories d'événements à ajouter à la plateforme.
benchmark_prix_marche_tunisie.csv	Prix	Positionnement tarifaire vs marché ; part réservations sous/au-dessus/alignées marché ; aide à l'offre prestataires.
external_holidays.csv	Calendrier	Taux de réservation les jours fériés ; panier moyen les jours fériés ; évolution du taux de conversion par type de jour.

3. Fichier 1 — Venues / Salles de fêtes

Fichier : venues_salles_tunisie_ranim.csv

3.1 Objectif métier

Alimenter les **suggestions des salles les plus populaires en Tunisie** (affichage par région, type d'événement, avec contact pour faciliter la prise de rendez-vous). Le fichier de référence contient des **vrais contacts** (téléphone, liens Instagram/Facebook de chaque lieu), régénéré par `generate_venues_salles_tunisie_ranim.py`. Aucune entrée fictive ; toutes les lignes ont un contact exploitable.

3.2 Description des données

Colonne	Description
venue_name	Nom du lieu (salle, club, espace événementiel). Hors doublons et lieux fictifs.
region	Zone ou adresse affichée (ex. Gammarth, Sousse, Hammamet).
gouvernorat	Gouvernorat tunisien standardisé (parmi les 24).
event_types	Types d'événements proposés (ex. Wedding; Birthday; Private Party; Corporate Event).
contact	Téléphone, ou lien Instagram/Facebook du lieu, ou email.

3.3 Méthode

- Fichier utilisé pour l'EDA** : `venues_salles_tunisie_ranim.csv` est généré par `generate_venues_salles_tunisie_ranim.py` (données embarquées).
- Scraping optionnel** : `scrape_venues_salles_tunisie.py` — urllib + regex sur `tunis.events` ; fiches détail pour téléphone, email, réseaux sociaux ; recherche web pour compléter Instagram/Facebook. Les liens vers `instagram.com/tunis.events` ne sont pas conservés ; les entrées « Lieu événementiel - [Gouvernorat] » sont exclues de l'export.

3.4 URLs sources (scraping)

URL	Rôle
https://tunis.events/fr/places	Liste des lieux (Tunis / Gammarth)
https://tunis.events/fr/places/sousse	Liste des lieux Sousse
https://tunis.events/fr/places/mahdia	Liste des lieux Mahdia
https://tunis.events/fr/places/hammamet	Liste des lieux Hammamet
https://tunis.events/fr/places/<slug>	Fiche détail (téléphone, email, réseaux sociaux)

3.5 Relations avec les données EventZilla

- **Suggestions salles** : alimentation du moteur de suggestions pour la sous-catégorie Venue ; filtrage par gouvernorat, region et event_types.
- **PROVIDER** : rapprochement possible avec PROVIDER.city pour enrichir la base ou dédupliquer.
- **EVENT** : croisement avec EVENT.type pour proposer des salles adaptées au type d'événement.

3.6 KPIs — Venues / Salles

Source : DataProjet/Scrapping/venues_salles_tunisie_ranim.csv

KPI	Formule / Méthode	Usage
Nombre de salles suggérables	COUNT(venue_name) — hors doublons et lieux fictifs.	Taille du catalogue utilisable pour suggestions.
Couverture géographique	COUNT(DISTINCT gouvernorat) / 24.	% de gouvernorats couverts par au moins une salle.
Part des salles joignables	COUNT(contact NOT NULL) / COUNT(total venues) × 100.	Qualité : % de lieux avec contact valide (tél, email, réseaux sociaux).
Répartition des salles par gouvernorat	COUNT(venue_name) GROUP BY gouvernorat.	Identifier les régions « stars » (ex. Tunis, Sousse).
Couverture par type d'événement	Pour chaque type attendu (Wedding, Birthday, Corporate, Private Party) : compter les lignes où event_types contient ce type.	Vérifier la pertinence et la diversité des types d'événements.

4. Fichier 2 — Tendances événementielles

Fichier : tendances_evenementielles_tunisie.csv

4.1 Objectif métier

Analyser les **potentiels de catégories d'événements à ajouter** à la plateforme (au-delà de Wedding, Birthday, Corporate Event, Private Party).

4.2 Description des données

Colonne	Description
category_name	Libellé de la catégorie (ex. Arts et Culture, Sport et Fitness).
category_slug	Identifiant URL (ex. evenements-arts-et-culture-tunisie).
source	Nom de la source (evenement.tn).
source_url	URL de la page catégorie sur evenement.tn.
event_count_observed	Nombre approximatif d'événements/liens observés sur la page (indicateur de tendance).

4.3 Méthode

- HTTP : urllib + regex (sans BeautifulSoup, sans API).
- Page d'entrée evenement.tn → extraction des liens catégories ; une requête par catégorie pour compter les liens (event_count_observed).

4.4 URLs sources

URL	Rôle
https://www.evenement.tn/evenements	Page liste des catégories
https://www.evenement.tn/evenements-arts-et-culture-tunisie/	Ex. Arts et Culture
https://www.evenement.tn/evenements-sport-et-fitness-tunisie/	Sport et Fitness

URL	Rôle
... (autres catégories)	Éducation, Technologie, Santé, Voyage, Affaires, Gastronomie, Mode, Famille, Geek Jeux, etc.

4.5 Relations avec les données EventZilla

- **CATEGORY / EVENT** : comparer les catégories EventZilla (Wedding, Birthday, Corporate, Private Party) aux catégories evenement.tn pour identifier les **nouvelles catégories** à ajouter.
- **Priorisation** : event_count_observed sert d'indicateur de potentiel pour décider quelles catégories intégrer en premier.

4.6 KPIs — Tendances

Sources : tendances_evenementielles_tunisie.csv ; CATEGORY.csv (catégories actuelles EventZilla).

KPI	Formule / Méthode	Usage
Potentiel par catégorie	event_count_observed par catégorie.	Identifier les catégories les plus demandées.
Part de chaque catégorie	(event_count_observed / SUM(event_count_observed)) × 100.	Pondération de chaque catégorie dans le marché global.
Catégories nouvelles vs couvertes	SET_DIFF(catégories marché, catégories EventZilla actuelles).	Roadmap produit : distinguer nouvelles catégories à intégrer.
Top N catégories à ajouter	TOP N(event_count_observed) hors catégories déjà couvertes.	Prioriser les ajouts pour maximiser attractivité.

5. Fichier 3 — Benchmark prix marché

Fichier : benchmark_prix_marche_tunisie.csv

5.1 Objectif métier

Fournir un **benchmark des prix du marché tunisien** (fichier par sous-catégorie × saisonnalité). Les **KPIs retenus** utilisent une valeur de référence **par sous-catégorie uniquement** (moyenne des 4 saisonnalités), sans mapping date → saisonnalité, pour le positionnement tarifaire des prestataires EventZilla (CDC 5.4, section 6).

5.2 Description des données

Colonne	Description
Subcategory	Venue (Salle), Catering (Traiteur), Entertainment, Decoration.
Saisonnalité	Haute Saison, Basse Saison, Intermédiaire, Ramadan.
Période indicative	Ex. Juin - Septembre, Novembre - Février.
Average Price (Marché TN)	Prix moyen observé (DT ou DT/pers.) — scraping + articles.

5.3 Méthode

- HTTP : urllib + regex (et lxml en option) ; scraping des URLs (elysee-du-lac, resaprivee, 1001-nights, tayara) ; données complémentaires à partir d’articles (Belvédère, OTOC, Iftar, etc.) ; agrégation par (Subcategory, Saisonnalité).

5.4 URLs sources

- **Scrapées** : elysee-du-lac.com/tarifs, resaprivee.com (traiteur), 1001-nights-palace.com, tayara.tn (décoration).
- **Articles (saisie manuelle)** : références Belvédère, OTOC, Iftars, mariage/entertainment.

5.5 Relations avec les données EventZilla

- **SERVICE + SUBCATEGORY** : jointure sur la sous-catégorie (Venue, Catering, Entertainment, Decoration). Mapping : SUBCATEGORY.name ↔ Subcategory du CSV (Venue (Salle), Catering (Traiteur), Entertainment, Decoration) — à normaliser avant jointure.
- **RESERVATION** : croiser final_price avec le **benchmark par sous-catégorie** (moyenne des 4 saisonnalités du fichier benchmark) pour calculer les écarts et le positionnement tarifaire. Aucun mapping date → saisonnalité n’est utilisé pour les KPIs.

5.6 KPIs — Benchmark prix

Les KPIs utilisent un **benchmark par sous-catégorie uniquement** (sans lien avec la date de réservation). Alignés CDC 5.4 « Benchmark prix prestataires » et section 6 (positionnement tarifaire).

Sources de données : RESERVATION (id_reservation, id_service, final_price, status) ; SERVICE (id_service, id_subcategory) ; SUBCATEGORY (id_subcategory, name) ; benchmark_prix_marche_tunisie.csv (Subcategory, Average Price (Marché TN) — parser en numérique).

benchmark_price = MOYENNE(« Average Price (Marché TN) ») sur les 4 lignes de la sous-catégorie (fichier benchmark — 4 saisonnalités). Sous-catégorie = celle de la réservation (RESERVATION → SERVICE → SUBCATEGORY). *Total* = réservations confirmées avec benchmark.

KPI	Formule (complète et concrète)	Objectif / Logique	Source(s) / Note
Part réservations sous marché	(COUNT(final_price < 0,85 × benchmark_price) / COUNT(total)) × 100. <i>Total</i> = toutes les réservations confirmées avec benchmark (même dénominateur pour les 3 parts).	Part des réservations vendues moins cher que le marché (≥15 % en dessous). Offres attractives ; risque marges faibles.	RESERVATION, SERVICE, SUBCATEGORY, benchmark_prix_marche_tunisie.csv (benchmark = moyenne par sous-catégorie).
Part réservations alignées marché	(COUNT(0,85 × benchmark_price ≤ final_price ≤ 1,15 × benchmark_price) / COUNT(total)) × 100.	Part des réservations dont le prix est proche du marché (±15 %). Zone cible, compétitif et perçu comme juste.	RESERVATION, SERVICE, SUBCATEGORY, benchmark_prix_marche_tunisie.csv (benchmark = moyenne par sous-catégorie).
Part réservations au-dessus marché	(COUNT(final_price > 1,15 × benchmark_price) / COUNT(total)) × 100.	Part des réservations vendues plus cher que le marché (≥15 % au-dessus). Position premium ; risque concurrence.	RESERVATION, SERVICE, SUBCATEGORY, benchmark_prix_marche_tunisie.csv (benchmark = moyenne par sous-catégorie).
Écart médian prix EventZilla vs benchmark (par sous-catégorie)	Écart par réservation = (final_price – benchmark_price) / benchmark_price ; KPI = MEDIANE de ces écarts (par sous-catégorie ou global).	Résumé robuste du positionnement (moins sensible aux valeurs extrêmes que la moyenne).	RESERVATION, SERVICE, SUBCATEGORY, benchmark_prix_marche_tunisie.csv (benchmark = moyenne par sous-catégorie).

6. Fichier 4 — Jours fériés (Holidays)

Fichier : external_holidays.csv

6.1 Objectif métier

Alimenter les **KPIs contextuels** liés aux jours fériés : taux de réservation les jours fériés, panier moyen les jours fériés, évolution du taux de conversion par type de jour (CDC 5.1, 5.3, 5.4).

6.2 Description des données

Colonne	Description
date	Date du jour férié (format DD/MM/YYYY).
local_name	Nom du jour férié en arabe (ex. عيد الاستقلال).
name	Nom en anglais/français (ex. New Year's Day, Independence Day).
country_code	Code pays (TN = Tunisie).
is_national	VRAI = jour férié national, FAUX = observance ou autre.
types	Type : Public, Observance, Season.
is_holiday	1 = jour férié.
day_of_week	Jour de la semaine (Monday, Tuesday, ...).
is_weekend	1 = samedi ou dimanche, 0 = jour ouvré.

6.3 Source et méthode

- **Script de génération** : DataProjet/Scrapping/scrape_holidays_tunisie.py .
- **Aucune API** : les données sont extraites depuis le HTML des pages web.
- **Aucun BeautifulSoup** : parsing par **regex** (re) sur le code HTML récupéré.
- **Bibliothèque** : urllib.request (stdlib Python) pour les requêtes HTTP.
- **Principe** : pour chaque année (ex. 2022–2026), requête GET sur l'URL source ; extraction des lignes du tableau (date, jour de la semaine, nom du jour férié, type) via expressions régulières ; conversion des dates au format DD/MM/YYYY ; calcul de day_of_week et is_weekend .
- **Fallback** : si la page ne renvoie pas de tableau exploitable, le script utilise la liste des **8 jours fériés nationaux fixes** tunisiens (dates officielles) pour générer un CSV valide (données réelles, non fictives).
- **Notebook dédié** : EDA_Scrapping_Holidays.ipynb permet d'exécuter le script et d'explorer les données.

6.4 URLs sources

URL	Rôle
https://www.timeanddate.com/holidays/tunisia/2022	Jours fériés Tunisie 2022
https://www.timeanddate.com/holidays/tunisia/2023	Jours fériés Tunisie 2023
https://www.timeanddate.com/holidays/tunisia/2024	Jours fériés Tunisie 2024
https://www.timeanddate.com/holidays/tunisia/2025	Jours fériés Tunisie 2025
https://www.timeanddate.com/holidays/tunisia/2026	Jours fériés Tunisie 2026

6.5 Relations avec les données EventZilla

- **EVENT** ↔ **external_holidays** : jointure sur la date pour identifier les événements en jour férié.
- **RESERVATION** ↔ **external_holidays** : jointure sur reservation_date pour taux de réservation et panier moyen les jours fériés.

6.6 KPIs — Holidays

Sources : external_holidays.csv (date, is_national, is_weekend) ; RESERVATION ; VISITORS (optionnel).

KPI	Formule / Méthode	Usage
Taux de réservation les jours fériés	(Nombre de réservations dont reservation_date ∈ dates jours fériés nationaux) / Nombre total de réservations × 100.	Contexte jours fériés.
Panier moyen jours fériés vs jours ouvrés	Moyenne(final_price) pour réservations en jour férié ; idem pour jours ouvrés ; comparer.	Panier moyen contextuel.
Évolution du taux de conversion par type de jour	Par type (férié / week-end / ouvré) : Taux = Réservations / Visitors × 100 ; comparer les taux.	Conversion par type de jour.

7. Synthèse — Fichiers et scripts

Fichier CSV	Script / origine	Méthode	Source principale
venues_salles_tunisie_ranim.csv	generate_venues_salles_tunisie_ranim.py	Données embarquées (vrais contacts) ; scraping optionnel : scrape_venues_salles_tunisie.py	tunis.events
tendances_evenementielles_tunisie.csv	scrape_tendances_evenementielles_tunisie.py	urllib + regex	evenement.tn
benchmark_prix_marche_tunisie.csv	scrape_benchmark_prix_marche.py	urllib + regex/lxml + données articles	elysee-du-lac, resaprivee, 1001-nights, tayara, articles
external_holidays.csv	scrape_holidays_tunisie.py	urllib + regex	timeanddate.com (holidays/tunisia/YYYY)

Rapport généré à partir du notebook EDA_Scrapping_Files_EventZilla.ipynb — Projet EventZilla.