

RAPPORT DE QUALITÉ — Projet EventZilla

TechCatalyse | Date : 29/01/2026

Table des matières

- 1. Présentation de l'activité TechCatalyse et intérêt d'EventZilla
 - 2. Description textuelle des colonnes par fichier
 - 3. Anomalies par fichier et décisions de gestion
 - 4. Relations entre fichiers (scénarios)
 - 5. Interprétations de la matrice de corrélation
-

1. Présentation de l'activité TechCatalyse et intérêt d'EventZilla

1.1. Activité de TechCatalyse

TechCatalyse est une entreprise technologique innovante spécialisée dans le développement de solutions digitales pour la gestion d'événements. Elle se positionne comme un acteur majeur dans l'écosystème technologique tunisien et vise à transformer l'industrie événementielle locale.

Mission :

- Faciliter et optimiser la gestion d'événements en connectant les organisateurs (bénéficiaires) avec des prestataires de services qualifiés.
- Simplifier la planification d'événements via une plateforme intuitive.
- Optimiser les budgets grâce à des outils d'aide à la décision (IA).
- Améliorer la qualité de service par un système d'évaluation et de suivi.
- Promouvoir l'innovation (IA, Big Data, Analytics) pour une expérience utilisateur exceptionnelle.

1.2. Intérêt d'EventZilla (référence CDC)

D'après le cahier des charges (CDC), le projet **EventZilla** est la solution de gestion des événements développée par TechCatalyse. Il vise à accompagner les utilisateurs dans l'organisation d'événements de manière intelligente et efficace.

EventZilla se compose de deux grandes parties :

- Un **système de budgétisation intelligent** permettant de gérer les événements selon les préférences et le budget.
- Un **espace de gestion des services et des réservations** pour explorer, comparer et réserver facilement les prestataires.

Contexte BI (CDC) : EventZilla génère quotidiennement des données sur les comportements des bénéficiaires, les performances des prestataires et les tendances du marché événementiel tunisien. Ces données sont à exploiter pour optimiser l'algorithme de suggestions, aider les prestataires à améliorer leur offre, identifier les opportunités de marché et prendre des décisions stratégiques basées sur les données. La qualité des données est donc un enjeu central pour la BI et la valeur métier de la plateforme.

2. Description textuelle des colonnes par fichier

Cette section reprend la description de chaque colonne telle que définie dans l'analyse exploratoire des données (EDA).

BENEFICIARY.csv — Bénéficiaires (clients)

- **id_beneficiary** (int) : Identifiant unique du bénéficiaire (client qui souhaite organiser un événement).
- **first_name** (string) : Prénom du bénéficiaire.
- **last_name** (string) : Nom de famille du bénéficiaire (valeurs manquantes : correction « Not found »).
- **email** (string) : Adresse email du bénéficiaire pour les communications (valeurs manquantes : correction « Not found »).
- **phone** (string) : Numéro de téléphone du bénéficiaire (manquant ou aberrant → correction « 00 000 000 »).

CATEGORY.csv — Catégories d'événements

- **id_category** (int) : Identifiant unique de la catégorie d'événement.
- **name** (string) : Nom de la catégorie (ex. : Wedding, Corporate, Birthday).

SUBCATEGORY.csv — Sous-catégories de services

- **id_subcategory** (int) : Identifiant unique de la sous-catégorie de service.
- **name** (string) : Nom de la sous-catégorie (ex. : Venue, Catering, Entertainment, Decoration, Photography, DJ).
- **id_category** (int) : Référence vers la catégorie parente (clé étrangère).

SERVICE.csv — Services proposés

- **id_service** (int) : Identifiant unique du service proposé.
- **price** (float) : Prix du service en TND.
- **description** (string) : Description détaillée du service proposé.
- **id_provider** (int) : Référence vers le prestataire qui propose ce service (clé étrangère).
- **id_subcategory** (int) : Référence vers la sous-catégorie du service (clé étrangère).
- **title** (string) : Titre/nom du service ; les valeurs « #VALEUR! » sont le défaut pour les services sans titre.

PROVIDER.csv — Prestataires

- **id_provider** (int) : Identifiant unique du prestataire de service.
- **name** (string) : Nom de l'entreprise ou du prestataire.
- **service_type** (string) : Type de service principal proposé (ex. : Decoration, Photography, DJ, Catering).
- **email** (string) : Adresse email du prestataire pour les communications.
- **phone** (string) : Numéro de téléphone du prestataire.
- **city** (string) : Ville où le prestataire est localisé.

EVENT.csv — Événements

- **id_event** (int) : Identifiant unique de l'événement organisé.
- **title** (string) : Titre ou description courte de l'événement.
- **event_date** (datetime) : Date et heure prévues pour l'événement.
- **budget** (float) : Budget alloué pour l'événement en TND.
- **type** (string) : Type d'événement (ex. : Birthday, Private Party, Wedding, Corporate Event).
- **id_beneficiary** (int) : Référence vers le bénéficiaire qui organise l'événement (clé étrangère).

RESERVATION.csv — Réservations

- **id_reservation** (int) : Identifiant unique de la réservation de service.
- **id_service** (int) : Référence vers le service réservé (clé étrangère).
- **id_event** (int) : Référence vers l'événement pour lequel le service est réservé (clé étrangère).
- **reservation_date** (datetime) : Date et heure de la réservation.
- **status** (string) : Statut de la réservation (confirmed, pending, cancelled).
- **final_price** (float) : Prix final payé pour le service en TND.

EVALUATION.csv — Évaluations

- **id_evaluation** (int) : Identifiant unique de l'évaluation.
- **id_reservation** (int) : Référence vers la réservation évaluée (clé étrangère).
- **rating** (int) : Note attribuée au service (généralement de 1 à 5 étoiles).
- **comment** (string) : Commentaire textuel optionnel sur le service reçu.

COMPLAINT.csv — Réclamations

- **id_complaint** (int) : Identifiant unique de la réclamation.
- **description** (string) : Description détaillée de la réclamation.
- **status** (string) : Statut de la réclamation (open, closed).
- **id_beneficiary** (int) : Référence vers le bénéficiaire qui a fait la réclamation (clé étrangère).
- **id_provider** (int) : Référence vers le prestataire concerné (clé étrangère).
- **subject** (string) : Sujet/catégorie de la réclamation (ex. : Service Quality, Late Delivery, Billing Issue, Product Defect).

VISITORS.csv — Trafic visiteurs

- **id** (int) : Identifiant unique de l'enregistrement.
- **date** (datetime) : Date de l'enregistrement du trafic (vérifier l'unicité des dates).
- **visitors** (int) : Nombre de visiteurs uniques sur la plateforme pour cette date.
- **reservations** (int) : Nombre de réservations effectuées ce jour-là.

MARKETING_SPEND.csv — Dépenses marketing

- **id** (int) : Identifiant unique de l'enregistrement. **month** (string) :
- Mois de la dépense marketing (format YYYY-MM).
- **marketing_spend** (float) : Montant dépensé en marketing pour ce mois en TND.
- **new_beneficiaries** (int) : Nombre de nouveaux bénéficiaires acquis grâce au marketing ce mois-là.

3. Anomalies par fichier et décisions de gestion

Pour chaque fichier sont indiqués les problèmes identifiés (valeurs manquantes, doublons, valeurs aberrantes) et la solution/décision de traitement, conformément à la section « Décisions de gestion des problèmes de qualité » de l'EDA.

BENEFICIARY

Problèmes : last_name manquant ; email manquant ; phone manquant ou aberrant (≤4 chiffres ou négatif).

Décisions :

1. last_name manquant → Remplacer par « Not found ».
2. email manquant → Remplacer par « Not found ».
3. phone manquant ou aberrant → Valeur par défaut « 00 000 000 ».

Remarque : Conserver en base les bénéficiaires sans email ni phone ; ne pas supprimer de client.
Indiquer le nombre de bénéficiaires sans email ni phone et le nombre de numéros aberrants.

CATEGORY

Problèmes : Aucun.

Décisions : Aucune action requise.

SUBCATEGORY

Problèmes : Aucun.

Décisions : Aucune action requise.

SERVICE

Problèmes : price manquant.

Décisions : price manquant → Remplir par la moyenne des prices des services ayant le même id_subcategory.

Remarque : Les valeurs « #VALEUR! » dans title sont le défaut pour les services sans titre.

PROVIDER

Problèmes : email manquant ; phone manquant.

Décisions : email manquant → Remplacer par « Not Found ». phone manquant → Remplacer par « 00 000 000 ».

EVENT

Problèmes : budget manquant.

Décisions : budget manquant → Remplir par la moyenne des budgets des événements ayant le même type (ou id_category si disponible via les réservations/services).

RESERVATION

Problèmes : Aucune valeur manquante.

Décisions : Aucune action requise.

EVALUATION

Problèmes : comment manquant.

Décisions : comment manquant → Remplacer par « Not found ».

COMPLAINT

Problèmes : description manquant.

Décisions : description manquant → Remplacer par « Not found ».

VISITORS

Problèmes : Aucune valeur manquante ; vérifier l'unicité des dates.

Décisions : Contrôler l'unicité des dates ; en cas de doublon, agréger (somme des visitors et des reservations par date) ou garder une occurrence ; voir section « Gestion des doublons ».

MARKETING_SPEND

Problèmes : month aberrant (MM > 12, ex. 2024-13, 2024-14).

Décisions : month aberrant → À partir de 2024-12, mapper les mois suivants sur 2025 (ex. 2024-13 → 2025-01 ; 2024-14 → 2025-02 ; etc.). En cas de doublon sur un même mois → fusionner par mois (somme des montants et des new_beneficiaries) ; voir section « Gestion des doublons ».

Gestion des doublons

BENEFICIARY et PROVIDER (doublons de colonnes email / phone)

Règles à appliquer selon le type de doublon :

1. Même email et phone différent

Conserver le bénéficiaire (ou le prestataire) : ne pas fusionner. Un même client peut avoir fait des réservations avec deux numéros différents (ex. personnel / pro) ; chaque ligne est considérée comme une entité distincte à conserver.

2. Même email et même phone

Conserver **la première instance** qui a fait une réservation en premier. Pour BENEFICIARY : trier par date de première réservation (via RESERVATION → EVENT) et garder l' `id_beneficiary` (ou l' `id_provider`) correspondant à cette première occurrence .

3. Même phone et emails différents

Conserver : ne pas fusionner. Plusieurs comptes (emails différents) peuvent partager le même numéro (foyer, entreprise) ; on conserve les lignes telles quelles.

- **CATEGORY / SUBCATEGORY (name)** : Fusionner ou renommer si doublons.
- **SERVICE (title)** : Ne pas fusionner ; unicité sur (id_provider, title) ou id_service.
- **EVENT (title)** : Conserver tel quel ; unicité sur id_event.
- **COMPLAINT (subject)** : Aucune fusion ; subject est une catégorie ; vérifier la cohérence des libellés.

VISITORS (doublons sur la date) : Une seule ligne par date .

MARKETING_SPEND (doublons sur le mois) : Une seule ligne par mois .

4. Relations entre fichiers (scénarios)

Chaque relation logique entre deux tables est décrite sous forme de scénario métier (aligné avec l'analyse des cardinalités et relations de l'EDA).

- **CATEGORY ↔ EVENT** : La catégorie est le type d'événement créé par le bénéficiaire (ex. mariage, entreprise, anniversaire). Les événements utilisent des services dont la sous-catégorie appartient à une catégorie.
 - **SUBCATEGORY ↔ SERVICE** : La sous-catégorie est le type de service offert par le prestataire (ex. lieu, traiteur, animation, décoration). Chaque service proposé est rattaché à une souscatégorie.
 - **BENEFICIARY → EVENT** : Le bénéficiaire (client) crée et organise des événements. Un même bénéficiaire peut organiser plusieurs événements.
 - **EVENT → RESERVATION** : Un événement regroupe plusieurs réservations de services (salle, traiteur, DJ, etc.). Une réservation lie un événement à un service.
 - **PROVIDER → SERVICE** : Le prestataire propose des services. Un prestataire peut proposer plusieurs services (dans une ou plusieurs sous-catégories).
 - **RESERVATION → EVALUATION** : Une réservation peut être évaluée par le bénéficiaire (note après le service). Une réservation a au plus une évaluation.
 - **BENEFICIARY / PROVIDER → COMPLAINT** : Un bénéficiaire peut déposer une réclamation à l'encontre d'un prestataire (liée à un service ou un événement).
-

5. Interprétations de la matrice de corrélation

La matrice de corrélation porte sur les variables numériques agrégées par événement (ex. nb_reservations, total_price, nb_evaluations, avg_rating, nb_complaints, budget). Les interprétations en tirets sont les suivantes :

- **nb_reservations ↔ total_price** : Plus un événement a de réservations, plus le montant total (total_price) est élevé — cohérent avec le volume de services réservés (corrélation positive forte, $|r| > 0,5$).
- **nb_reservations ↔ nb_evaluations** : Plus un événement a de réservations, plus il reçoit d'évaluations — les colonnes sont fortement corrélées (taux de retour client).
- **total_price et nb_evaluations** : Lien modéré ($r \approx 0,37$) — plus de chiffre d'affaires par événement s'accompagne souvent de plus d'évaluations.

Les autres paires de variables (id_event, budget, id_beneficiary, avg_rating, nb_complaints) ne présentent pas de corrélation forte ($|r| \leq 0,5$) dans les données agrégées par événement ; les relations métier passent principalement par les clés étrangères et les volumes (réservations, prix, évaluations).
